

TP: Multi-hop QA usando RAG y Agentes

Procesamiento del Lenguaje Natural

Maestría en Ciencia de Datos

Universidad de San Andrés

Juan Manuel Pérez

Bruno Bianchi

20 de mayo de 2026

1 Objetivos

En este trabajo práctico intentaremos replicar los resultados para la tarea de QA en varios pasos (*multi-hop QA*), concretamente sobre el dataset HotPotQA [2]. Se busca evaluar diferentes técnicas para la resolución de este problema. Para esto vamos a utilizar Retrieval-Augmented Generation (RAG) y agentes, y comparar los resultados obtenidos con los del paper original.

Las preguntas de HotPotQA requieren razonar sobre múltiples documentos para llegar a la respuesta. A continuación se muestra un ejemplo:

Pregunta: Which magazine was started first,
Arthur's Magazine or First for Women?

Contextos de soporte:

1. Radio City (Indian radio station)

Radio City is India's first private FM radio station and was started on 3 July 2001. It broadcasts on 91.1 megahertz from Mumbai, Bengaluru, Lucknow and New Delhi.

2. Arthur's Magazine

Arthur's Magazine (1844-1846) was an American literary periodical published in Philadelphia in the 19th century. Edited by T.S. Arthur, it featured work by Edgar A. Poe, J.H. Ingraham, Sarah Josepha Hale, Thomas G. Spear, and others. In May 1846 it was merged into Godey's Lady's Book.

3. First for Women

First for Women is a woman's magazine published by Bauer Media

Group in the USA. The magazine was started in 1989.

4. ...

Respuesta: Arthur's Magazine

Si bien para un LLM actual podemos resolver esto poniendo todo los documentos en el contexto de la pregunta, vamos a resolver un problema levemente más complejo inspirados en el paper de ReACT [3]. Vamos a solamente dar la pregunta y, dada una base de datos vectorial que contenga todos los posibles contextos del dataset, diseñaremos una solución basada en RAG o en agentes para resolver la tarea.

2 Consignas

Las siguientes consignas son de carácter obligatorio:

- Generar una base de datos vectorial con todos los posibles contextos de las preguntas del dataset.
- Intentar resolver la tarea usando RAG sobre esta base de datos (solo las instancias del set de validación).
- Desarrollar un agente que, dada una pregunta, pueda responderla. Puede elegir una de las siguientes opciones: que el agente interactúe con la base de datos vectorial, o bien que interactúe con Wikipedia.
- Evaluar también el desempeño de un modelo de lenguaje sin utilizar RAG ni agentes, es decir, utilizando solo el modelo de lenguaje para responder a las preguntas.
- Realizar una comparación de los resultados obtenidos con los del paper original.

Todo el código debe ser realizado en Python, sólo utilizando las librerías *transformers*, *langchain*, *datasets* o cualquier otra que hayamos utilizado en clase.

3 Informe

Realizar un breve informe (entre 3 y 5 páginas) con aproximadamente las siguientes secciones:

- Introducción (efímera!)
- Metodología (Datos, modelos, técnicas)

- Resultados
- Conclusiones

Se espera que en el informe se describa brevemente la tarea de HotPotQA, los modelos utilizados, los resultados obtenidos, y las conclusiones del trabajo, abordando las consignas descriptas anteriormente.

4 Modelos, datos y recursos

Si bien los estudiantes pueden utilizar cualquier modelo de lenguaje, se recomienda comenzar con modelos de lenguaje de Google, OpenAI o bien modelos de lenguaje del hub de *huggingface*. Recomendamos en este último caso utilizar modelos de lenguaje pequeños como **Gemma 4** de Google, disponibles en el hub de Hugging Face¹, o bien **phi-3-mini-4k-instruct** [1]².

Respecto a los datos de HotPotQA, tienen que usar los datos del siguiente dataset: https://huggingface.co/datasets/hotpotqa/hotpot_qa.

5 Evaluación

Se evaluará la calidad de la experimentación, el análisis de los resultados, y la calidad del informe. Los resultados en términos de performance de los modelos **no** serán el criterio principal de evaluación.

Se sugiere, para mayor entendimiento de la tarea, leer la bibliografía citada en este enunciado.

6 Entrega

La entrega del trabajo final se realizará en formato de informe en Markdown o PDF, adjuntando el correspondiente código y se deberá subir al campus virtual.

La fecha de entrega máxima es el miércoles 10 de junio del 2026 a las 23:59 hs.

References

- [1] Marah Abdin et al. “Phi-3 technical report: A highly capable language model locally on your phone”. In: *arXiv preprint arXiv:2404.14219* (2024).
- [2] Zhilin Yang et al. *HotpotQA: A Dataset for Diverse, Explainable Multi-hop Question Answering*. 2018. arXiv: 1809.09600 [cs.CL]. URL: <https://arxiv.org/abs/1809.09600>.

¹<https://huggingface.co/collections/google/gemma-4-680e5ff063ad09e2d5e4e9a8>

²<https://huggingface.co/microsoft/Phi-3-mini-4k-instruct>

- [3] Shunyu Yao et al. “React: Synergizing reasoning and acting in language models”. In: *arXiv preprint arXiv:2210.03629* (2022).